煤矿安全大模型———矿途智护者

1	项目简介			
2	项目架构图			
	3 数据构造模块			
	3.1	从煤矿安全领域法律法规等文件获取数据	2	
	3.2	从煤矿从业人员入职考试题库获取数据	4	
	3.3	煤矿历史事故案例、事故处理报告获取数据	5	
	3.4	自我认知数据获取	7	
4	模型征	微调模块	8	
5	RAG ₹	模块	8	
6	知识	图谱构建模块	9	
7	部署模块11			
8	测试计	评估	11	

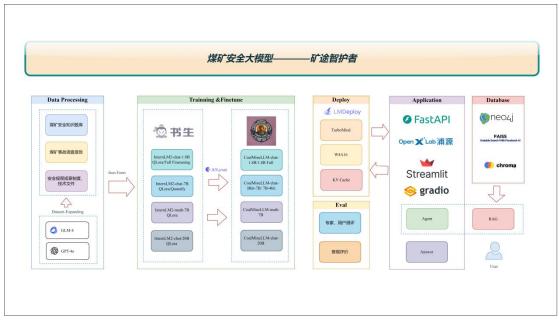
1 项目简介

近年来,国家对煤矿安全生产的重视程度不断提升。为了确保煤矿作业的安全,提高从业人员的安全知识水平显得尤为重要。鉴于此,目前迫切需要一个高效、集成化的解决方案,该方案能够整合煤矿安全相关的各类知识,为煤矿企业负责人、安全管理人员、矿工提供一个精确、迅速的信息查询、学习与决策支持平台。 为实现这一目标,我们利用包括煤矿历史事故案例、事故处理报告、煤矿安全领域法律法规、安全操作规程、规章制度、技术文档以及煤矿从业人员入职考试题库等在内的丰富数据资源,通过微调 InternLM2 模型,构建出一个专门针对煤矿事故和煤矿安全知识智能问答的煤矿安全大模型。

本项目的特点如下:

- 支持煤矿安全领域常规题型解答,如:单选题、多选题、判断题、填空题等 (针对煤 矿主要负责人及安管人员、煤矿各种作业人员)
- 支持针对煤矿安全领域法律法规、安全规程规章制度、技术等文档内容回答(如《中华 人民共和国矿山安全法》、《煤矿建设安全规程》)
- 支持煤矿历史事故案例,事故处理报告查询,提供事故原因详细分析、事故预防措施以 及应急响应知识

2 项目架构图



总体技术路线如下:

- 收集煤矿历史事故案例、事故处理报告、煤矿安全领域法律法规、安全操作规程、规章制度、技术文档以及煤矿从业人员入职考试题库等在内的丰富数据资源。
- 借助 GLM-4, GPT-4o 大模型,通过编写 Prompt 脚本从文本自动抽取问答对,包括单轮对话和多轮对话,同时借助人工收集题库,构造自我认知数据,最后人工审核,转变成 Xtuner 微调数据格式。
- 微调方面,使用 Xtuner 工具,采用 QLora 方法分别对 InternLM2-Chat-1.8B、InternL M2-Chat-7B、InternLM2-Math-7B、InternLM2-Chat-20B 模型进行微调,并分别命名为 CoalMineLLM_InternLM2-Chat-1_8B、CoalMineLLM_InternLM2-Chat-7B、CoalMineLL M_InternLM2-Math-7B、CoalMineLLM_InternLM2-Chat-20B。同时采用 Full Finetunin g 对 InternLM2-Chat-1.8B 模型全参微调,并命名为 CoalMineLLM_InternLM2-Chat-1_8 B-full,使用 LMDeploy 工具,采用 W4A16 对 InternLM2-Chat-7B 模型量化,并命名为 CoalMineLLM_InternLM2-Chat-7B-4bit。
- 为了模型高效准确回答来自用户的相关问题,我们采用 RAG 技术,针对用户的 query, 检索来自向量数据库和知识图谱的相关知识信息,来增强回答效果。
- 部署模块,借助 LMDeploy 工具,进行高效推理部署到 streamlit、gradio 展示,以及 部署到 OpenXlab 平台上。
- 在知识图谱构建模块,借助 GLM-4,编写信息抽取 Prompt 抽取三元组关系,最后存入到 Neo4j 中。(现在正在使用信息抽取指令数据集来微调 InternLM2 模型。)
- 在评测模块,针对煤矿事故处理报告、规章制度文件等数据源,采用人工和 GPT-40 方式生成单轮和多轮测试数据集,以及收集未在训练集中出现的考试题库数据。采用主观、客观评估,针对选择题、判断题等题型,采用客观评估;其他类型问题,使用 GPT-40 和专家来评估。

3 数据构造模块

3.1 从煤矿安全领域法律法规等文件获取数据

使用 GLM-4 模型,通过编写指令,抽取数据。其 Prompt 模板如下: def return random prompt():

system_prompt = "根据下面提供有关煤矿安全领域文本,请你仔细通读全文,你需要依据该文本: \n\n#####\n{}#####\n 尽可能给出多样化的问题和对应的回答。我们将用于人工评估 GLM-4 模型对问答对数据的完成情况。要求:\n".format(content)

system_prompt += "1. 生成问题有价值且遵守该文本信息,回答准确专业。\n"

system prompt += "2. 生成问答对不能重复。\n"

system_prompt += "3. 问题多样化,同个问题可以换成不同表述方式,但意思保持不变。\n"

system_prompt += "4. 为问题生成作为<input>,不应该只包含简单的占位符。<input>应提供实质性的内容问题,具有挑战性。字数不超过" + str(random.randint(80, 120)) + "字。\n"

system_prompt += "5. <output>应该是对问题的适当且真实的回答,不能只回复答应或拒绝请求。如果需要额外信息才能回复时,请努力预测用户意图并尝试回复,但不能胡编乱造。<output>的内容应少于" + str(random.randint(512,1024)) + "字。\n\n"

system_prompt += "请给出满足条件的 20 条 JSON 格式数据,并存储在一个列表中,便于整理使用,不要输出无法的字符,只要列表形式存储 JSON 数据\n"

return system prompt

最终变成数据格式形如:

"system": "你是一个煤矿安全领域的知识达人,你对相关煤矿安全规章规程制度、技术等文档非常熟悉。请你专业正确地解答用户想问的煤矿安全相关问题。",

"input": "请提供新建矿井立井井筒冻结法施工的具体要求。",

"output":"新建矿井立井井筒冻结法施工需要遵守以下要求:冻结深度必须穿过风化带延深至稳定的基岩 10m以上,第一个冻结孔必须全孔取芯,钻孔时必须测定钻孔的方向和偏斜度,偏斜度超过规定时必须及时纠正,冻结管必须采用无缝钢管并焊接或螺纹连接,开始冻结后必须经常观察水文观测孔的水位变化,并在确定冻结壁已交圈后才能进行试挖。"

"system": "你是一个煤矿安全领域的知识达人, 你对相关煤矿安全规章规程制度、技术等文档非常熟悉。请你专业正确地解答用户想问的煤矿安全相关问题。",

"input": "煤矿安全规程中,对于新建矿井的立井井筒冻结法施工有哪些具体要求?",

"output":"新建矿井立井井筒冻结法施工需要遵守以下要求:冻结深度必须穿过风化带延深至稳定的基岩 10m以上,第一个冻结孔必须全孔取芯,钻孔时必须测定钻孔的方向和偏斜度,偏斜度超过规定时必须及时纠正,冻结管必须采用无缝钢管并焊接或螺纹连接,开始冻结后必须经常观察水文观测孔的水位变化,并在确定冻结壁已交圈后才能进行试挖。"

```
]
},
```

1

3.2 从煤矿从业人员入职考试题库获取数据

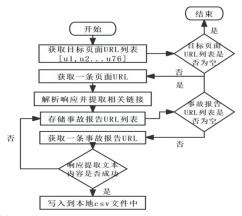
人工收集数据形如(以选择题为例):

1	input	output
2	关于《安全生产法》的立法目的,下列表述中不准确的是()A加强安全生产工作 C.保障人民群众生命和财产安全 B.防止和减少生产安全事故 D.提升经济发展速度	D
3	下列关于《安全生产法》适用范围的理解,正确的是() A.生产经营单位的安全生产适用本法,但消防安全和道路交通安全、铁路交通安全、水上交通安全、民用航空安全以及核与辐射安全、特种设备安全输外 B.生产经营单位的安全生产,适用本法有关法律、行政法规对消防安全和道路交通安全、铁路交通安全、水上交通安全、民用航空安全以及核与辐射安全、水上交通安全、完固和宏之之以及核与辐射安全、特产资量设计。适用本法消防安全和道路交通安全、水上交通安全、民用航空安全以及核与辐射安全、特上资量单位的安全生产。适用本法消防安全和通路交通安全、张生交通安全、民用航空安全以及核与辐射安全、水上交通安全、民用航空安全以及核与辐射安全、该由其他有关法律、行政法规的规定	В
4	下列关于安全生产工作方针的表述,最准确的是() A以人为本、安全第一、预防为主 B.安全第一、预防为主、政府监管 C.安全第一、预防为主、综合治理 D.安全第一、预防为主、群防群治	c
5	关于安全生产工作机制,不正确的表述是() A.政府负责 B.职工参与 C.行业自律 D.社会监督	А
	某公司董事长由上一级单位总经理张某兼任,张某长期在外地不负责该公司日常工作。该公司总经理安某在国外税产学习,期间日常工作由常务副总经理徐某负责,分管安全生产工作的副总经理姚某协助其工作。根据(安全生产法)有关规定,此期间对该公司的安全生产工作全面负责的人是() A 安某 B 永某	с

最后通过脚本,变成:

3.3 煤矿历史事故案例、事故处理报告获取数据

先通过编写爬虫脚本,从煤矿安全网爬取事故报告数据,其爬取流程图,如下所示。



爬取后, 然后整理成如下所示:

```
1.2023年6月8日6时,黑河市兴边矿业有限公司东部一区二段底分层采煤工作面发生顶
                                     板事故,造成1人死亡,直接经济损失182.33万元。
                                     事故直接原因:工作面放炮崩歪单体液压支柱,工人在空顶情况下违意打设支柱,冒落的岩
                                     石砸倒支柱,支柱砸伤其头部致死。
                                     事故间接原因:
                                    (一)兴边煤矿
                                     1.技术管理存在不足。一是对复合顶板管理技术认知不足,未认真组织炮采工艺可行性分析
                                     论证。二是作业规程贯彻不认真,事故工作面作业规程贯彻记录存在代签现象。
                                    2.安全管理混乱。一是违章实施爆破作业。事故当班班长张相国未取得特种作业(爆破)操作资格证实施爆破作业。二是未执行"一炮三检"和"三人连锁爆破"制度。事故当班爆破现
                                     场无瓦检员和爆破工,起爆前未按规定检查起爆地点的甲烷浓度。三是未按规定给井下作业
                                     人员配发人员位置监测识别卡,事故工作面当班3名工人未随身携带识别卡
                                     3.现场安全检查责任不落实。现场安检员和带班安全矿长对于事故当班存在的从业人员在未
                                     取得特种作业(爆破)操作证实施爆破作业、未执行"一炮三检"和"三人连锁爆破"制度和
                                     对工人违章空顶作业等行为均未及时发现并予以制止。
                                    4.职工安全培训教育不到位。一是现场作业人员安全风险辨识能力不足,安全意识、自主保安意识不强,在未确认现场安全的情况下违章进入空顶区域打设单体液压支柱。二是教育培
                                     训管理不严格, 从业人员存在未经培训合格入井作业情况。
                                     (二)爱辉区煤管局
                                     1.主矿安全监管制度存在漏洞。《爱辉区煤炭生产安全管理局驻矿安全监管员管理办法》履
                                     职要求中,对定点驻矿盯守人员每月入井次数和夜班入井次数做出了规定,但未明确入井时
                                     长,也未对煤矿从业人员容易产生疲劳困倦和精神不集中的零点班入井次数作出规定,驻矿
                                     盯守效果打折扣。《办法》规定,定点驻矿盯守每组每月不得少于25次入井,其中定点驻
                                     矿盯守夜班入井次数不得少于7次,兴边煤矿驻矿员5月份入井22次,未达到规定次数,
                                     且无零点班入井记录
                                     2.驻矿盯守责任落实不到位。爱辉区煤管局驻矿队要求兴边煤矿驻矿员对该矿井下作业地点
                                     每4天完成一次全覆盖检查,6月3日至6月8日期间,驻矿员未到该工作面进行过检查。
驻矿员对该矿日常检查过程中对该矿存在的违章爆破作业、作业规程贯彻记录存在代签现象、
                                     未执行"一炮三检"和"三人连锁爆破"制度等问题未能及时发现。
                                     3.联系包保责任落实有差距。爱辉区煤管局联系包保兴边煤矿责任人未按照《爱辉区煤矿联
                                     系包保和巡查盯守工作制度(试行)》第七条第(五)项要求,组织对该矿开展5月份的月度安
                                     全检查。
页面: 1/651 字数: 419724 拼写检查: 打开 * 校对
```

最后借助 GPT-4o, 基于指令生成多轮对话数据, 形如:

```
[
{
    "conversation": [
    {
```

"system": "你是一名煤矿安全领域的知识达人,提供有关煤矿安全规程、事故预防措施和应急响应的知识。",

"input": "你好!",

"output": "您好,我是一名煤矿安全领域的知识达人,请问有什么可以帮助您?"

}, {

"input": "2023 年 4 月 27 日陕西省府谷县国能业有限公司矿发生了什么事故?"、

"output": "2023 年 4 月 27 日,陕西省府谷县国能业有限公司矿 201-1 切眼改造掘进工作面发生了一起顶板事故,导致 1 人死亡。"

},
{

"input": "请告诉我这起事故的直接原因是什么?",

"output": "事故直接原因是 201-1 新切眼掘进工作面未按《作业规程》要求进行临时支护,工人违章进入空顶区域作业,被冒落的顶板砸压。"

```
},
        {
          "input": "那么,这起事故的间接原因有哪些?",
          "output": "事故间接原因包括现场安全管理混乱、技术管理存在漏洞、安
全生产主体责任落实不到位、安全教育培训不到位和安全监管有差距。具体表现在作业规程
执行不严格、安全技术措施审批把关不严、安全管理人员配备不足、安全管理人员岗位职责
不明确等方面。"
        },
        {
          "input": "为了避免类似事故,煤矿企业应该采取哪些措施?",
          "output": "为了避免类似事故,煤矿企业应严格执行作业规程,加强现场
安全管理,确保临时支护措施到位,强化技术管理,建立完善的技术管理体系,落实安全生
产主体责任,加强安全教育培训,提高职工安全意识和风险辨识能力,同时加强安全监管,
确保监管工作细致认真。"
        },
        {
          "input": "感谢您的详细解答!",
          "output": "不客气,很高兴能帮助到您。如果您还有其他问题,欢迎继续
提问。"
     1
  },...
1
3.4 自我认知数据获取
通过如下脚本,生成20条自我认知数据
#coding=utf-8
import json
# 设置用户的名字
name = 'A100 换你 AD 钙奶团队'
# 设置需要重复添加的数据次数
n = 200
#初始化 OpenAI 格式的数据结构
data = [
  {
     "conversation": [
        {
          "system": "",
          "input": "你好,你是谁?",
```

"output": "您好! 我是{}研发的煤矿安全领域大语言模型。我们的团队成员来自安徽理工大学、中国矿业大学、北京化工大学、中国人民解放军总医院等多所高校/企业的博士、硕士、本科生以及个人开发者,共同参与了我的研发工作。我具备强大的语言处理能力和丰富的知识储备,旨在为煤矿企业负责人、安全管理人员、矿工等用户提供关于煤矿事故、煤矿安全规程规章制度及相关安全知识的智能问答服务。通过与我互动,您可以快速获取准确、全面的信息查询、学习和决策支持。我致力于成为您在煤矿安全管理领域的重要助手,帮助您提高安全意识、掌握安全规程、预防和应对煤矿事故,保障矿工的生命安全和企业的可持续发展。如果您有任何关于煤矿安全方面的问题或需求,欢迎随时向我提问,我将竭诚为您提供帮助。".format(name)

```
}
]
}
```

#通过循环,将初始化的对话数据重复添加到 data 列表中

for i in range(n):

data.append(data[0])

将 data 列表中的数据写入到一个名为'personal_assistant.json'的文件中with open('煤矿安全数据/personal assistant.json', 'w', encoding='utf-8') as f:

- # 使用 json.dump 方法将数据以 JSON 格式写入文件
- # ensure ascii=False 确保中文字符正常显示
- # indent=4 使得文件内容格式化,便于阅读

json.dump(data, f, ensure ascii=False, indent=4)

4 模型微调模块

环境安装、数据准备、模型准备、下载配置文件、修改配置参数、模型训练、转换成 huggingface 格式、模型合并、测试模型。详见: https://github.com/yaosenJ/CoalQA/blob/main/finetune/README.md

5 RAG 模块

模块目的:

根据用户的问题,检索对应信息以增强回答的专业性,使 CoalQA 的回答更加专业可靠。检索内容包括但不限于以下几点:

- 煤矿安全相关的问答对
- 煤矿安全相关的案例

技术路线:

这个 RAG 系统各部分的技术路线分别是:

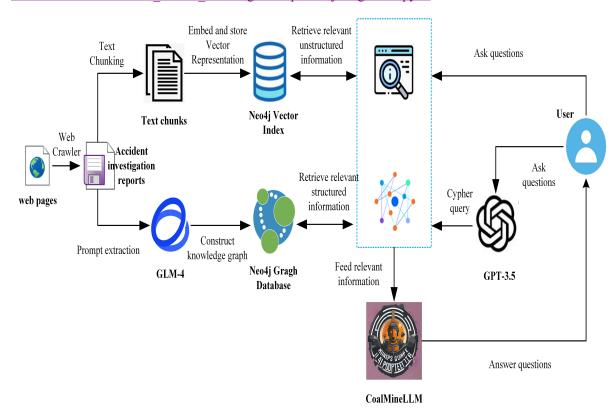
- Embedding 模型: BAAI/bge-small-en-v1.5
- LLM 基座: CoalMineLLM_InternLM2-Chat-1_8B CoalMineLLM_InternLM2-Chat-7B CoalMineLLM InternLM2-Chat-20B CoalMineLLM InternLM2-Math-7B
- 使用 BAAI/bge-reranker-large 做检索后精排

- 向量数据库:
- FAISS: 是 Facebook 开源的一个高效的向量相似性搜索库。它为大规模向量检索提供了 多种索引结构和搜索算法,能够快速查找与给定向量最相似的向量。FAISS 擅长处理超 高维度的向量数据,在图像检索、推荐系统等场景有广泛应用。

RAG 详细指南见: https://github.com/yaosenJ/CoalQA/blob/main/rag/README.md 后续计划

- 利用评测框架 RAGAS 对系统进行评估
- 构建二分类数据对向量模型以及精排模型进行训练以提升性能 使用 Neo4j 和 Langchain 集成非结构化和图知识增强煤矿事故 QA, 见:

https://github.com/yaosenJ/CoalQA/blob/a1b7af0e04f708e60eb00c8f12fe08092947d133/demo/CoalMineLLM-InternLM2 Chat-1 8B-integrated-qa-neo4j-langchain.ipynb



6 知识图谱构建模块

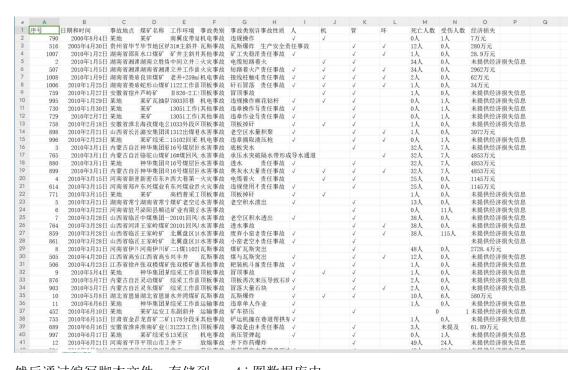
使用 GLM-4 对煤矿事故信息抽取,如:

instruct: "你是专门进行实体抽取的专家。请从 input 中抽取出符合 schema 定义的实体,不存在的实体类型返回空列表。请按照(实体,实体类别)的格式回答。"

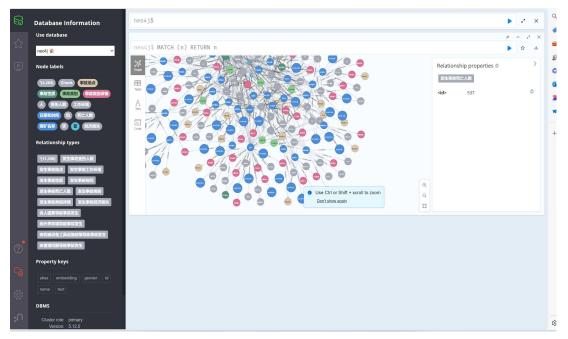
"schema": [时间,事故地点,煤矿名称,煤矿事故,死亡人数,受伤人数,经济损失]

"input": "2023 年 8 月 21 日,陕西省延安市延川县新泰煤矿(以下简称新泰煤矿)发生一起重大瓦斯爆炸事故,造成 11 人死亡、11 人受伤,直接经济损失 1919.2 万元"

"output": (2023 年 8 月 21 日,时间),(陕西省延安市延川县,事故地点),(新泰煤矿,煤矿名称),(重大瓦斯爆炸事故,煤矿事故),(11 人,死亡人数),(11 人,受伤人数),(1919.2 万元,经济损失)最终抽取信息内容,如下所示:



然后通过编写脚本文件,存储到 neo4 j 图数据库中。



现已经构造好信息抽取数据,来微调 InternLM2 模型。

然后通过脚本把上面数据, 转成如下指令数据。

"instruction": "{"instruction": "你是专门进行实体抽取的专家。请从 input 中抽取出符合 sche ma 定义的实体,不存在的实体类型返回空列表。请按照 JSON 字符串的格式回答。", "sche ma": ["事故时间", "事故地点", "组织机构", "煤矿名称", "事故类别", "工作面", "死亡人数", "受伤人数", "经济损失"], "input": "2016 年 4 月 25 日,铜川照金煤矿透水事故,造成11 名被困井下的矿工全部遇难。"}"

"output": "{"事故时间": ["2016 年 4 月 25 日"], "事故地点": ["铜川"], "煤矿名称": ["照金煤矿"],"事故类别": ["透水事故"],"工作面": ["井下"]", "死亡人数": ["11 名"]"}"
}

7 部署模块

openxlab 部署

- 登陆 OpenXLab, 创建 Streamlit 应用
- 选择配置,创建应用,如果需要更多的硬件资源,在这里进行申请
- 等待构建、启动
- 项目体验

本地部署、基于 LMDeploy 量化部署, 详见 https://github.com/yaosenJ/CoalQA 中部署模块。

8 测试评估

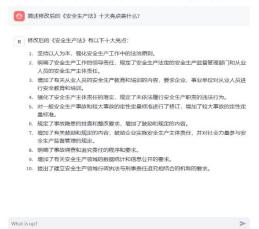




○ 煤矿安全大模型--矿途智护者

○ 煤矿安全大模型--矿途智护者

What is up?







- 请问您能提供有关黑河市兴边矿业有限公司事故的信息吗?
- R 2023年6月8日6时,黑河市兴边矿业有限公司东部一区二段底分层采煤工作面发生顶板事故,造成1人死亡,直接经济损失182.33万元。事故直接原因是工作面放炮崩歪单体液压支柱,工人在空顶情况下违章打设支柱,冒落的岩石砸倒支柱,支柱砸伤其头部致死。事故间接原因包括: 1. 技术管理存在不足,如对复合顶板管理技术认知不足,作业规程贯彻不认真等; 2. 安全管理混乱,如违章实施爆破作业,未执行"一炮三检"和"三人连锁爆破"制度,未按规定给井下作业人员配发人员位置监测识别卡等; 3. 现场安全检查责任不落实,现场安检员和带班安全矿长对于存在的违章行为未及时发现并制止; 4. 职工安全培训教育不到位,现场作业人员安全风险辨识能力不足,安全意识不强。

